학원 문의 대행 음성 에이전트의 시스템 설계와 동일 음성 모델 기반 플랫폼 구성 비교

강유준*, 딩옌*, 박찬원*, 김규림*, 유종민*, 이관유**, 김재수***

Design of an Academy Inquiry Voice Agent and Comparison of Platform Configurations with the Same Speech Model

Kang Yujune*, Ding Yan*, Park Chanwon*, Kim Gyulim*, You Jongmin*,
Lee Kwanyu**, Kim Jaesoo***

요 약

본 논문은 질문별 상태 관리, 재발신 제어, 플랫폼별 결과 변환을 갖춘 학원 문의 대행 음성 에이전트를 설계·구현하고, 자동 테스트 197개와 ClawOps 실통화 3건으로 웹 접수부터 결과 표시까지의 흐름을 확인하였다. 같은 음성 모델을 쓰는 ClawOps와 Vapi 구성은 연구자가 학원 역할을 맡은 전화 통화로 비교하였다. 플랫폼별 7통의 서버 녹음에서 지연 중앙값은 ClawOps 1.57초, Vapi 1.42초로 Vapi만 1.5초 목표 이내였으나 통화 단위로는 차이를 확정할 수 없었다. 끊김으로 의심되는 완전 무음은 Vapi에서만 12회 나타났고 월 비용은 ClawOps가 낮아, 소규모 측정이지만 지연만으로는 플랫폼을 고를 수 없다.

Abstract

We build a voice agent for academy inquiries with per-question state tracking, retry control, and per-platform result conversion, and check its end-to-end flow with 197 automated tests and three real ClawOps calls. In seven role-played calls each, ClawOps and Vapi with the same speech model had median latencies of 1.57 s and 1.42 s; only Vapi met the 1.5 s target, but the call-level difference was inconclusive. Complete silences suggesting audio breaks appeared only on Vapi (12 times), while ClawOps cost less, so latency alone cannot decide the platform.

Key words

voice agent, private academy inquiry, response latency, speech continuity, system architecture

*경북대학교 컴퓨터학부, rkddbwns2@gmail.com, dingyan769@gmail.com, pyb8804@gmail.com, limq031123@gmail.com, yjongmin7@gmail.com, **㈜팔랑크스시스템즈, daegu5302@gmail.com, ***경북대학교 컴퓨터학부, kjs@knu.ac.kr(교신저자)

※ 본 연구는 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었음 (2021-0-01082)

Ⅰ. 서 론

빈자리처럼 자주 바뀌는 정보나 수업 시간은 학원에 직접 전화해 물어야 할 때가 많은데, 학부모와 학원의 통화 가능 시간이 다르면 이를 바로 확인하기 어렵다. 이에 학부모가 고른 질문을 AI가 학원에 전화해 묻고 결과를 돌려주는 음성 에이전트를 설계하였다. 에이전트는 음성 모델을 외부 음성 플랫폼에 연결해 통화하는데, 본 연구는 전화번호, 음성 통화, 문자와 실시간 이벤트를 하나의 API로 지원하는 국내 AI 통신 API 플랫폼인 ClawOps와 실시간 음성 AI 에이전트 구축 플랫폼인 Vapi를 사용하였다. 같은 모델이라도 플랫폼마다 음성 전송과 버퍼 처리 방식이 달라 응답이 늦어지거나 말이 끊기는 정도가 다를 수 있다. 응답 지연과 말 끊김은 통화를 어색하게 만들고 버퍼 설정이 다 공개되지는 않으므로, 플랫폼은 실제 통화로 비교해 골라야 한다. 본 연구의 기여는 두 가지이다. 첫째, 확인된 부정과 미확인 응답을 구분하는 질문별 상태 관리, 재발신 제어, 플랫폼별 결과 변환 구조를 설계·구현하고, 목업 연동과 ClawOps 실통화로 처리 흐름을 확인한다. 둘째, 같은 음성 모델과 설정을 적용한 ClawOps와 Vapi의 응답 지연, 발화 연속성, 대화 행동을 실제 통화로 비교하고 월 비용을 추정한다.

Ⅱ. 관련 연구

과업 지향 음성 대화에서 RavenClaw[1]는 과업별 대화 제어와 공통 대화 기능을 분리하였다. 본 연구도 문의, 재발신, 결과 저장을 플랫폼별 음성 처리와 분리하고 둘 사이를 워커로 잇는다. 응답 시점에 관한 연구[2]는 발화 중 쉼 때문에 무음 길이만으로 발화 종료를 판단하기 어렵다는 점과 언어 문맥 등으로 턴 전환을 예측하는 방법을 정리하였다. 따라서 본 연구는 응답 지연과 함께 쉼에 끼어드는지, 확인 질문 뒤 답을 기다리는지도 관찰한다.

전송 측면에서 RFC 3551[3]은 음성·영상을 실시간 전송하는 RTP(Real-time Transport Protocol)의 음성 기본 패킷화 간격을 20ms로 권고하고, Ramjee 등[4]은 재생 대기를 늘리면 늦게 도착한 음성의 손실은 줄지만 지연이 늘어나는 관계를 다루었다. 4.3절은 이 관계로 지연과 끊김을 해석한다.

Ⅲ. 시스템 설계

3.1 구성과 처리 흐름

시스템은 웹 화면(Next.js), 백엔드(FastAPI), MySQL, Redis 발신 큐, 음성 워커, 외부 음성 플랫폼으로 구성한다(그림 1). 문의자가 학원과 질문을 골라 접수하면 백엔드가 운영시간, 대기 순서, 동시 통화 수를 고려해 발신 작업을 워커에 넘긴다. 워커는 플랫폼별 요청과 이벤트를 공통 형식으로 바꾸고 통화 결과를 질문별 JSON으로 돌려주며, 재발신 판단과 결과 저장은 백엔드가 맡는다. Vapi는 통화 후 지정한 형식의 분석 결과를 주므로 항목을 그대로 옮기도록 설계하였고, ClawOps 워커는 전사에서 질문별 학원 답변을 키워드 규칙으로 찾아 예·아니오·미확인으로 판정해 같은 형식으로 보낸다.

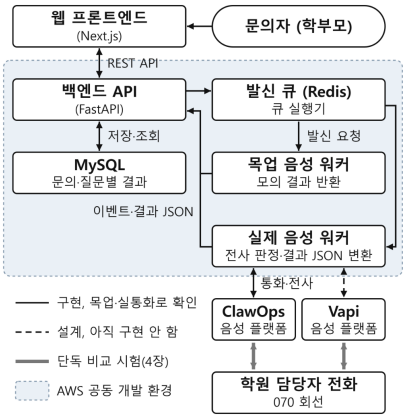


그림 1. 학원 문의 대행 시스템 설계 구조와 구현 범위
Fig. 1. System architecture and implementation scope for private academy inquiries.

3.2 질문별 결과와 재시도 관리

선택형 질문 여섯 가지(통학 차량, 픽업, 반 수준, 빈자리, 레벨 테스트, 수업 시간) 중 1~6개를 묻고, 상담 수락 여부와 가능 시간은 항상 묻는다. 질문별 결과에는 질문 여부(asked), 답변 여부(answered), 예·아니오(yes_no), 미확인 이유(reason), 상세 답변(detail)을 둔다. 부정 답변은 answered=true,

yes_no=false로, 미확인은 answered=false, yes_no=null로 기록해 학원이 '없다'고 답한 것과 확인하지 못한 것을 구별한다.

재시도 이력을 남기기 위해 문의 ID와 통화 시도 ID를 나눠 한 문의에 여러 통화를 연결하고, 같은 문의가 두 번 접수되지 않도록 Idempotency-Key를 쓴다. 부재중이면 300초 뒤 다시 걸고, 결과는 통화를 예약한 시점부터 600초까지 기다린다(모두 개발 단계 값). 그 뒤에 도착한 결과는 이미 정리된 문의 결과를 덮어쓰지 않도록 원본으로만 남긴다.

3.3 구현 범위

현재 백엔드 개발 API 0.4.0과 DB 테이블 21개를 구현하였다. 커밋 6a8bbce 기준 자동 테스트 197개(백엔드 132개, 음성 목업 30개, 실제 워커 35개, 실제 전화 제외)를 모두 통과하였으며, 이 시험은 문의 등록과 조회, 상태 변경, 재발신, 중복 요청, 인증, 워커와 주고받는 결과(부정과 미확인 답변의 구분 포함)를 검사한다. 또한 AWS EC2 공동 개발 환경에서 웹 접수부터 질문별 결과 표시까지를 ClawOps 실통화 3건으로 확인하였으며, 시험 중 실발신은 지정 계정과 허용 번호 1개, 문의당 1회로 제한하였다. Vapi 워커는 아직 구현하지 않았고, 4장의 비교는 이와 별도로 수행하였다.

3.4 개인정보 처리

학원 담당자의 음성은 두 플랫폼 모두 OpenAI에서 처리되나 처리 위치는 확인되지 않았고, Vapi는 녹음과 전사를 미국에 저장한다. 서비스 이용자인 문의자에게는 개인정보 처리방침과 국외 이전 동의를 회원가입 때 한 번 받고 그 시각을 기록하도록 설계하였으며, 현재 이용약관 동의와 그 시각 저장을 구현하였다. 그러나 학원 담당자에게는 첫인사에서 AI 상담원임과 녹음 사실을 알리는 데 그치므로, 학원 측 동의 방법은 과제로 남는다(4.3절).

IV. 실험 및 평가

4.1 실험 방법

연구자 한 명이 학원 담당자 역할을 맡아, 두 플랫폼의 AI가 건 전화를 받아 같은 대본으로 응대하였다. ClawOps는 자체 에이전트를 썼고, Vapi는 인터넷 전화의 통화 연결 신호 규약인 SIP(Session Initiation Protocol)로 ClawOps의 070 회선에 직접 연결하여 음성이 미국의 Vapi 서버를 거친다. 모델, 추론 강도, 음성, 프롬프트는 같게 맞췄으나 플랫폼 내부 처리와 통신 경로는 통제하지 못했으므로, 이는 같은 모델을 쓰는 두 플랫폼 구성의 탐색적 비교이며 지연에 포함된 구간도 다르다(표 1). 대본은 문의 상황이 다른 A~E 다섯 가지이고, 응답 수를 채우려고 A와 D를 한 번씩 더 건 A2·D2를 합쳐 플랫폼별 7통을 지연 분석에 썼다. 발화 중 쉼을 일부러 넣은 대본 H는 끼어들기 시험용이라 지연 분석에서 제외하였다.

표 1. 비교 실험의 조건
Table 1. Conditions of the comparative experiment.

항목	설정
음성 모델	GPT-Live(gpt-live-1), 보조 모델 gpt-5.6-luna, 추론 강도 none, 음성 marin
대본·질문	빈자리·수업 시간·상담. 대본 A~E, 추가 A2·D2(지연 분석 7통), 쉼·끼어들기 시험 H
녹음·측정	플랫폼별 8통, ClawOps 서버 녹음 기준(Vapi는 미국 왕복 포함, 휴대폰망 제외)
학원 역할	동일 연구자 1명, 휴대전화 수신

응답 지연은 사람 발화가 끝난 시점부터 AI 발화가 시작된 시점까지로 정의하였다. 처음에는 음성 구간 검출과 화자 임베딩으로 자동 측정하였으나 화자와 경계가 어긋난 구간이 있어, 최종 값은 연구자 한 명이 측정 도구(그림 2)에서 소리 크기(−60dB)로 나뉜 구간을 들으며 화자와 경계를 직접 정해 다시 쟀다. Vapi는 되짚는 질문 뒤 AI가 답을 기다리지 않아 생긴 간격 1개와 요약 첫 음절 1개, 응답이지만 0.8~1.0초로 유독 짧고 경계가 애매한 간격 3개를, ClawOps는 불분명한 조각 1개를 빼고 ClawOps 49개, Vapi 44개를 분석하였다(뺀 간격을 넣은 결과는 4.2절).

완전 무음은 0.3초 이상인 AI 발화 안에서 표본값의 절댓값이 1 이하인 상태가 0.12~0.3초 이어진 구간으로 정의하고, 플랫폼별 AI 발화 전체(ClawOps 6.2분, Vapi 6.5분)에서 세었다. 같은 음성

모델이라 자연스러운 쉼은 양쪽에 비슷할 것이므로, 한쪽에만 많은 완전 무음은 전송 과정의 끊김으로 의심되는 흔적으로 본다. 지연의 합격 기준은 과제 제안서의 1.5초 요구를 기업 멘토와 협의해 응답 전체의 중앙값 1.5초 이내로 정하였고, 응답을 짧은 순으로 늘어놓았을 때 90%, 95% 위치의 값인 p90, p95를 함께 본다. 같은 통화의 응답은 서로 독립이 아니므로, 통화별 중앙값에 두 집단 값의 순위로 분포 차이를 보는 비모수 검정인 Mann-Whitney U 검정(양측)을 쓰고, 통화를 복원 추출하는 부트스트랩(20,000회)으로 중앙값 차이의 95% 구간을 구하였다. 통화 요약이 대본의 정답과 맞는지는 생성형 AI로 예비 확인만 하고 평가에서 제외하였다. 측정 기록과 분석 스크립트는 프로젝트 저장소[5]에 공개하였다.

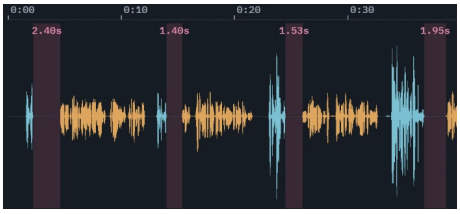


그림 2. 응답 지연 측정 도구(ClawOps A2 통화). 하늘색은 사람, 주황색은 AI, 붉은 띠는 응답 간격이다.
Fig. 2. Latency measurement tool(ClawOps call A2).

4.2 실험 결과

직접 측정한 응답 전체의 중앙값은 ClawOps 1.57초, Vapi 1.42초로 Vapi만 1.5초 목표 이내였고, p95는 1.98초와 1.78초로 둘 다 1.5초를 넘었다(표 2, 그림 3). 표 2는 4.1절의 제외 기준을 적용한 플랫폼별 응답 수와 지연 통계이고, 그림 3은 응답 하나를 점 하나로 찍고(주황색은 A2·D2 통화) 플랫폼별 중앙값, p95, 1.5초 목표를 선으로 그린 것이다. 통화별 중앙값은 ClawOps 1.42~1.89초, Vapi 1.27~1.58초였다. 이 통화별 중앙값의 Mann-Whitney U 검정은 $p=0.038$로 5% 수준에서 유의하였으나 중앙값 차이의 부트스트랩 95% 구간은 −0.01~0.35초로 0을 포함하고 통화도 7통씩뿐이므로, Vapi가 더 빠른 경향은 있으나 차이를 확정할 수는 없다. 뺀 Vapi 간격 5개를 다시 넣으면 Vapi 중앙값은 1.40초로 오히려 짧아져, 제외가 Vapi에 유리하지 않았다. Vapi도 7통 중 2통은 통화 중앙값이 1.5초를 넘었으며, 1.5초를 넘은 응답의 비율(표 2)은 경계 판정에 민감해 보조 지표로만 본다.

표 2. 4.1절의 제외 기준을 적용한 직접 측정 지연
Table 2. Manually measured response latency after the exclusions in Section 4.1.

항목	ClawOps	Vapi
응답 수	49	44
평균 / 중앙값	1.63 / 1.57초	1.45 / 1.42초
p90 / p95 / 최대	1.95 / 1.98 / 2.40초	1.67 / 1.78 / 2.12초
1.5초 넘은 응답	33 (67%)	18 (41%)

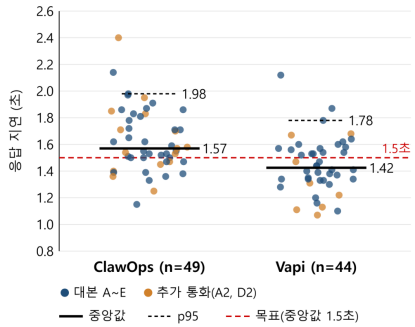


그림 3. 플랫폼별 응답 지연(점 하나가 응답 하나)
Fig. 3. Response latency by platform (one point per response).

두 플랫폼 모두 8통 전부에서 첫인사에 AI·녹음 고지를 포함하였고, 발화 중 0.9~7.3초 쉼이 있는 대본 H에서도 끼어들지 않았다. 되짚기 후 답을 기다리지 않은 경우는 ClawOps 3회, Vapi 6회였으며, 4.1절에서 뺀 Vapi 간격 1개도 이런 행동에서 생겼다. AI 발화의 완전 무음은 ClawOps 0회, Vapi 12회(분당 약 1.8회)였고 같은 ClawOps 서버에서 녹음한 사람 발화에서는 두 플랫폼 모두 2~3회였으므로, Vapi의 무음은 AI 음성이 오가는 경로에서 생긴 것으로 보인다. Vapi는 응답이 빠른 경향이었지만 완전 무음과 답을 기다리지 않은 횟수는 더 많았다.

4.3 논의

ClawOps 고객지원 답변[1]에 따르면 GPT-Live 모드에서 입력은 100ms 단위로 묶고 출력은 100ms

1)개인적 교신(ClawOps 고객지원팀 이메일, 2026-10-14).

분량을 쌓아 보내므로(출력 대기 평균 약 80ms), 입력 대기 평균 50ms를 더해 약 130ms의 버퍼 대기가 생긴다. Vapi는 입력이 RFC 3551[3]의 20ms 간격이라면 입력 대기가 평균 10ms 정도이고 출력 대기는 알려지지 않았다. 이 버퍼 차이는 중앙값 차이 0.15초의 일부를 설명할 수 있으나, Vapi 통화는 미국의 Vapi 서버를 한 번 더 거치고 두 플랫폼의 내부 처리 시간도 재지 않아 원인별 기여는 확인하지 못하였다. 한편 출력 버퍼는 재생 대기처럼 지연을 늘리는 대신 끊김을 줄이므로[4], 완전 무음이 느린 ClawOps에는 없고 빠른 Vapi에만 있었던 결과와 방향이 같다.

비용은 월 100분 사용을 가정하면 ClawOps 약 29,500원, Vapi 약 131,930원으로 추정되며, 차이의 대부분은 Vapi를 070 회선에 붙이는 SIP 직접연결 비용 월 99,000원이다(환율 1,400원/$, 부가세 포함, 전사·요약 비용 제외).

실험은 연구자 한 명이 하루 동안 플랫폼별 8통을 받은 소규모 역할 시험이고, 서버 녹음이라 휴대폰망 구간이 빠졌다. 결과는 실험 당시의 플랫폼 설정에 한정되며, 참여자와 날짜를 늘린 반복 측정이 필요하다. 응답 경계도 연구자 한 명이 판정하여 독립 판정으로 재현성을 확인해야 하고, 완전 무음이 실제로 들리는 끊김인지도 청취로 확인하지 않았다. 외부 SIP 트렁크를 통한 Vapi 연결은 시험에서는 동작했으나 Vapi 설정 문서[6]의 지원 범위에 명시되지 않아, 국내 회선으로 서비스할 때의 안정성은 보장되지 않는다. 질문별 판정은 전사 키워드 규칙이라 시험 통화에서 되짚기 때 학원이 답을 고치거나 AI 발화가 끊긴 경우 오판이 있었고, 규칙은 보완했으나 통화가 적어 정확도는 평가하지 않았다. 판정 정확도와 휴대폰 쪽 체감 지연 평가, 학원 측 동의 방법은 향후 과제이다.

V. 결 론

본 연구는 질문별 상태 관리, 재발신 제어, 플랫폼별 결과 변환 구조를 설계·구현해 자동 테스트와 ClawOps 실통화 3건으로 흐름을 확인하고, 같은 음성 모델을 쓰는 ClawOps와 Vapi 구성을 연구자가 학원 역할을 맡은 전화 통화로 비교하였다. 플랫폼별 7통의 소규모 서버 녹음에서 지연 중앙값은 ClawOps 1.57초, Vapi 1.42초로 Vapi만 1.5초 목표 이내였으나, 통화 단위로는 차이를 확정할 수 없었다. 반면 끊김으로 의심되는 완전 무음은 Vapi에서만 12회 나타났고 월 비용도 ClawOps가 낮아, 응답 지연만으로는 플랫폼을 고를 수 없다. 앞으로 질문별 판정 정확도를 평가하고 Vapi 워커를 연결할 예정이다.

참 고 문 헌

[1] D. Bohus and A. I. Rudnicky, "The RavenClaw dialog management framework: Architecture and systems", Computer Speech & Language, vol. 23, no. 3, pp. 332-361, 2009.

[2] G. Skantze, "Turn-taking in Conversational Systems and Human-Robot Interaction: A Review", Computer Speech & Language, vol. 67, Art. 101178, 2021.

[3] H. Schulzrinne and S. Casner, "RTP Profile for Audio and Video Conferences with Minimal Control", RFC 3551, July 2003.

[4] R. Ramjee, J. Kurose, D. Towsley, and H. Schulzrinne, "Adaptive playout mechanisms for packetized audio applications in wide-area networks", Proc. IEEE INFOCOM '94, vol. 2, pp. 680-688, 1994.

[5] Academy-calling-agent, GitHub repository, https://github.com/academy-calling-team/Academy-calling-agent (accessed Oct. 19, 2026).

[6] Vapi, "GPT-Live settings and compatibility", https://docs.vapi.ai/gpt-live/configuration (accessed Oct. 19, 2026).